

Automatización de codificación temática en entrevistas mediante LLMs

Natali Alba Tobias

María José Sierra Barreto

Neurociencia Social II

LINCIPH

Universidad Externado de Colombia

Departamento de Matemáticas

Ciencia de Datos

Bogotá D.C.

2025

1. Introducción

1.1 Contexto

En la actualidad, la investigación de la orientación política en estudiantes universitarios toma una gran relevancia, pues es fundamental para comprender cómo se forman las identidades políticas en una etapa clave del desarrollo personal y académico, lo que permite anticipar tendencias en la participación cívica y diseñar estrategias educativas que fomenten el pensamiento crítico y la inclusión. La universidad no solo es un espacio de formación académica, sino también un entorno donde los jóvenes desarrollan y expresan sus identidades políticas. Estas prácticas incluyen desde la participación en movimientos estudiantiles hasta la organización de eventos y debates que reflejan sus inquietudes sociales y políticas (Liliana et al., 2010).

Por lo anterior, es importante reconocer y fomentar estos espacios de participación como parte integral del proceso educativo, ya que contribuyen al desarrollo de ciudadanos críticos y comprometidos con su entorno. Además, en un contexto de polarización creciente, entender las inclinaciones políticas estudiantiles ayuda a las universidades a crear entornos que promuevan el diálogo abierto y respetuoso, evitando que las instituciones adopten posturas oficiales que puedan limitar la diversidad de opiniones y el libre intercambio de ideas (Powell, 2025).

Particularmente, desde El Laboratorio Interdisciplinar de Ciencias y Procesos Humanos (LINCIPH), se ha llevado a cabo una exhaustiva investigación entorno a este tema: *“Interacciones Políticas De Los Jóvenes Universitarios En La Red Social Digital Facebook Durante La Contienda Electoral Por La Presidencia Del Año 2022: Una Perspectiva Desde La Neurociencia Social.”*. En este se han llevado a cabo diversos estudios como el Test de personalidad BIS/BAS, Tests de Reconocimiento de Emociones y Estados Mentales, Cuestionario de Auto Posicionamiento Ideológico, entrevistas abiertas, EEG, GSR, entre otros, con el fin de entender a los individuos que eran estudiados en diversas dimensiones (psicométrica, hermenéutica filosófica y biométrica).

En este sentido, las entrevistas cobran una gran relevancia en este análisis, pues la forma de que un estudiante se expresa acerca de sus vivencias personales y su posición política revela con mayor profundidad los marcos interpretativos que utiliza para comprender el mundo social, su relación con la autoridad, los valores que prioriza y las experiencias que han moldeado su pensamiento político. Esta dimensión cualitativa permite captar matices que los instrumentos estandarizados no siempre logran identificar, como contradicciones internas, procesos de cambio ideológico o la influencia de contextos familiares, académicos y culturales en la construcción de su orientación política.

Para el presente proyecto, se utilizaron entrevistas que provienen de jóvenes universitarios de Tulua y fueron realizadas durante la contienda electoral para la presidencia en Colombia en el año 2022. Estos textos fueron previamente codificados manualmente por los investigadores del laboratorio, generando una matriz con variables como: tipo de familia, edad de inicio en redes sociales, ideología política, tipo de discurso, acceso a redes, intención de voto, entre otras. Esta tarea resulta muy laboriosa, pues analizar individualmente cada entrevista en estas múltiples

variables requiere de mucho tiempo, por lo que la automatización de este proceso mediante técnicas de Procesamiento de Lenguaje Natural (PLN) se plantea como una respuesta a esta problemática.

Esta no es la primera vez que se plantea usar PLN para análisis político, por ejemplo ha sido usado para clasificar opiniones y sentimientos expresados en textos, como en la tesis de Nabib Ahmed en Harvard, donde se desarrolló una plataforma que utiliza técnicas de PLN para identificar la orientación política de textos, clasificándolos en un espectro que va de muy conservador a muy liberal. Este enfoque permite analizar grandes volúmenes de datos textuales, como publicaciones en redes sociales, para comprender las tendencias ideológicas y los temas de interés político de manera más eficiente que los métodos tradicionales basados en encuestas (Ahmed, 2022).

Asimismo, el PLN es muy usado para análisis de discursos, como en el estudio de Salomon Orellana, quien aplicó estas técnicas para analizar los manifiestos de partidos políticos en Nueva Zelanda entre 1987 y 2017. Utilizando métodos como la estimación de similitud entre documentos y el modelado de temas, el estudio logró identificar cómo evolucionaron las ideologías partidarias a lo largo del tiempo, qué temas fueron priorizados y cómo se expresaban las actitudes hacia diferentes áreas políticas. Estos hallazgos no sólo ofrecieron una visión detallada de la dinámica política neozelandesa, sino que también demostraron el potencial del PLN para complementar y enriquecer los análisis tradicionales en ciencias políticas, especialmente en contextos de cambios significativos en los sistemas partidarios (Bisgin & Mani, 2022). Este es un punto de partida relevante para la presente investigación.

1.2 Modelos de Lenguaje de Gran Escala

En la actualidad, un gran subcampo de la Inteligencia Artificial es la Inteligencia Artificial Generativa, la cual se refiere a la capacidad que tiene la Inteligencia Artificial de crear contenido original, como texto, imágenes o audio. Dentro de esta, se encuentran los Modelos de Lenguaje de Gran Escala (LLM, por sus siglas en inglés, Large Language Models), los cuales son modelos basados en redes neuronales enfocadas en el PLN, principalmente en la compresión y generación de texto como lo hacen los seres humanos, entendiendo los patrones del lenguaje (Bell, 2022).

La arquitectura predominante en estos modelos es el *Transformer* (Vaswani et al., 2017), los cuales se entrenan sobre millones o billones de palabras para predecir secuencias y representar el significado lingüístico de manera contextual e introdujo el mecanismo de *autoatención*, reemplazando redes recurrentes y permitiendo un procesamiento paralelo más eficiente y preciso. Gracias a la creciente disponibilidad de los mismos en plataformas como Hugging Face, se ha demostrado una notable capacidad para identificar patrones semánticos complejos en grandes volúmenes de texto.

Pero hay que tener en cuenta que estos modelos, Existe una técnica llamada Fine-Tuning, en la que de acuerdo a unos textos base, se puede especializar el LLM a una tarea en particular, pero esto requiere básicamente re entrenar la red neuronal.

1.3 Objetivos

Teniendo en cuenta la información presentada, el objetivo principal de esta investigación es automatizar la codificación de nuevas entrevistas en la matriz sugiriendo automáticamente posibles etiquetas para las variables de análisis, reduciendo así la carga del análisis cualitativo manual.

Para esto, los objetivos específicos de investigación son los siguientes:

- Aplicar redes neuronales preentrenadas en el análisis de entrevistas.
- Evaluar el uso de modelos de PLN para identificar patrones en el texto.
- Explorar diferentes aplicaciones como el análisis de sentimiento y otras tareas relevantes.

2. Metodología

2.1 Conceptos y Herramientas

Antes de explicar el paso a paso seguido, es necesario tener en cuenta ciertos conceptos clave y herramientas utilizadas:

Query: Consulta a realizar. En este caso se toman como oraciones con los que se van a comparar los fragmentos para posteriormente hacer la predicción.

Librería spaCy: Fue usada para la limpieza básica de los textos de las entrevistas: eliminación de espacios innecesarios y normalización de palabras (quitar tildes, eñes y muletillas o palabras extendidas como “entoonces”).

Expresiones Regulares (regex): Son usadas para detectar patrones específicos en los textos.

Tokenización: Es el proceso de dividir un texto en unidades mínimas de análisis llamadas *tokens* (como palabras o subpalabras). Los modelos de tipo Transformer tokenizan usando vocabularios propios que dividen palabras en fragmentos (subwords) que han sido entrenados previamente.

Embeddings: Son representaciones numéricas densas de texto que permiten al modelo procesar el significado de cada token.

Similitud del coseno: Mide el ángulo entre dos vectores de texto en un espacio vectorial, esto para indicar qué tan parecidos son entre sí. Se calcula

$$\text{sim}(A, B) = \cos(\theta) = \frac{\vec{A} \cdot \vec{B}}{\|\vec{A}\| \|\vec{B}\|}$$

Dónde:

- $\vec{A} \cdot \vec{B}$ es el producto punto entre los vectores A y B
- $\|\vec{A}\|$ y $\|\vec{B}\|$ son las normas (magnitudes) de los vectores

TF-IDF (Term Frequency-Inverse Document Frequency): Es una medida que evalúa la importancia de una palabra en un documento respecto a un corpus. Se calcula así:

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \text{IDF}(t)$$

Donde:

- $\text{TF}(t, d) = \frac{\text{Número de veces que aparece el término } t \text{ en el documento } d}{\text{Número total de términos en el documento } d}$
- $\text{IDF}(t) = \log \left(\frac{N}{n_t} \right)$

Y

- N es el número total de documentos en el corpus,
- n_t es el número de documentos que contienen el término t.

2.1.2 LLMs utilizados

Como se mencionó previamente, los LLMs en la actualidad se basan principalmente en

Transformers, los cuales utilizan métodos de autoatención: en estos, una secuencia de entrada (por ejemplo, una oración) se convierte primero en embeddings. A partir de estos embeddings se generan tres vectores por token: query (Q), key (K) y value (V) mediante transformaciones lineales.

Luego, se calculan los puntajes de atención haciendo el producto punto entre los vectores query y key, y se escalan dividiendo por la raíz cuadrada de la dimensión del vector key para estabilizar el entrenamiento: esto representa qué tanta atención le debe prestar un token a otros token para entender su significado en el contexto, por ejemplo con la frase "El gato que estaba en el sofá dormía plácidamente.", cuando el modelo intenta procesar el token "dormía" le da más peso de atención a "gato" y "sofá" (porque ayudan a entender quién duerme y dónde). Esta representación contextual de cada token se llama peso- de atención.

Finalmente, estos puntajes se normalizan con la función softmax, convirtiéndolos en probabilidades de atención, que indican la importancia relativa de cada token respecto a los demás; estas probabilidades se usan para hacer una suma ponderada de los vectores value, lo que permite que el modelo se enfoque en los elementos más relevantes de la secuencia al generar la salida (Ibm, 2025).

Ahora bien, en la plataforma Hugging Face hay una gran diversidad de modelos pre entrenados disponibles para ser usados gratuitamente, entre los que hay LLMs, y específicamente hay una familia de modelos llamada E5 (Embedding for Embedding-based retrieval with Encoder-only models).

Aunque la disponibilidad de LLMs en plataformas como Hugging Face facilita el acceso y la experimentación, es crucial considerar que la ejecución de modelos de gran escala, especialmente a través de servicios en la nube o APIs de inferencia (como los ofrecidos por Hugging Face, AWS, GCP, Azure), presenta un conjunto de desafíos importantes que deben sopesarse.

Correr un modelo en la nube tiene ventajas claras (como no necesitar hardware potente), pero también varias desventajas importantes que deberían considerarse.

Dado que el presente proyecto se realizó con limitaciones significativas en cuanto a recursos de cómputo, presupuesto económico y tiempo disponible, estas desventajas inherentes a la ejecución en la nube afectaron directamente las decisiones tomadas:

- **Costo económico:** Servicios como Hugging Face Inference API o las instancias en la nube cobran por uso. Para un proyecto con recursos económicos limitados, realizar un gran número de peticiones o procesamiento intensivos en modelos muy grandes alojados en la nube podría resultar prohibitivamente costoso. Esto influyó en la necesidad de buscar alternativas más eficientes o limitar la escala de experimentación con modelos de pago o de alto consumo de recursos en la nube.

- **Latencia y velocidad:** Aunque no fue el factor más crítico para la automatización de codificación (que puede procesarse en lotes), la latencia inherente de enviar datos a través de internet para ser procesados en servidores externos y recibir la respuesta podría ser una limitación si se buscara una aplicación en tiempo real o con requisitos estrictos de respuesta inmediata.
- **Dependencia de conexión:** La ejecución en la nube requiere una conexión a internet constante. Esto, si bien es común, introduce un punto de falla dependiente de la estabilidad de la red y del servicio del proveedor.
- **Menor control:** Al usar APIs de inferencia o modelos hospedados, se tiene menos control directo sobre el modelo "físico" y su configuración. Esto puede dificultar la personalización o afinación específica que podría ser ideal para el dominio particular de las entrevistas en español colombiano.
- **Escalabilidad técnica compleja:** Si bien la nube *facilita* la escalabilidad teórica, gestionarla uno mismo en instancias dedicadas implica complejidad técnica (monitoreización, balanceo de carga, actualizaciones), lo cual requiere tiempo y experiencia, recursos que estaban limitados en el contexto del proyecto.

Estas consideraciones, sumadas a la limitación directa de recursos de cómputo que impidió incluso probar localmente el modelo más grande, e5-mistral-7b-instruct. esto se explica a continuación en donde para la elección del modelo se estaba buscando un balance entre rendimiento y viabilidad técnica y económica dentro de las restricciones del proyecto.

Entendiendo cómo funcionan los Transformers, para este proyecto se realizaron pruebas con 4 LLMs que, aunque no generan texto, pueden producir representaciones numéricas del significado de una oración o documento en un espacio vectorial. Los modelos fueron los siguientes:

1. *paraphrase-multilingual-MiniLM-L12-v2*

- **Parámetros:** aproximadamente 33 millones.
- **Dimensión del embedding:** 384 dimensiones.
- **Detalles:** Este modelo, desarrollado por Microsoft en 2020, es una versión ligera basada en la arquitectura Transformer con 12 capas. Está optimizado para eficiencia computacional y es adecuado para tareas de similitud semántica multilingüe.

2. *intfloat/multilingual-e5-base*

- **Parámetros:** aproximadamente 110 millones.
- **Dimensión del embedding:** 768 dimensiones.
- **Detalles:** Lanzado en 2023 por el equipo de investigación intfloat, este modelo utiliza la arquitectura Transformer con 12 capas y está enfocado en tareas como recuperación de información y búsqueda semántica. Fue entrenado bajo el esquema text2vec, emparejando preguntas y respuestas o fragmentos similares.

3. *intfloat/e5-large*

- **Parámetros:** aproximadamente 335 millones.

- **Dimensión del embedding:** 1024 dimensiones.
- **Detalles:** Esta versión más poderosa del modelo anterior cuenta con 24 capas, lo que le otorga una mayor capacidad. Aunque es más costoso computacionalmente, ofrece un alto rendimiento en tareas de recuperación de información, utilizando una sintaxis especial para diferenciar entre consultas y pasajes/documentos.

4. *intfloat/e5-mistral-7b-instruct*

- **Parámetros:** 7 mil millones.
- **Dimensión del embedding:** 4096 dimensiones.
- **Detalles:** Basado en el modelo Mistral 7B, este modelo ha sido adaptado para la extracción de embeddings útiles en tareas de recuperación semántica. Aunque es pesado computacionalmente, ofrece una alta eficiencia y rendimiento en tareas de búsqueda semántica. No fue adoptado finalmente por falta de recursos de cómputo.

Se hicieron intentos con estos modelos para la generación de embeddings, pero con el que se encontraron mejores resultados fue intfloat/e5-large, posteriormente en la sección de Discusión se hará una comparación entre los mismos.

2.1.3 Métricas

En el contexto de clasificación de textos, hay 3 métricas clave que se tuvieron en cuenta para evaluar el rendimiento del modelo a la hora de clasificar nuevas entrevistas.

1. *Top-k accuracy*

- Esta métrica calcula el número de veces que la etiqueta correcta está entre las etiquetas top k predichas (ordenadas por puntajes predichos). Está en un rango de 0 a 1.
- **Fórmula:**

$$\text{Top-}k \text{ Accuracy} = \frac{1}{N} \sum_{i=1}^N 1 \left\{ y_i \in \hat{y}_i^{(1:k)} \right\}$$

Donde:

- y_i : etiqueta verdadera para el ejemplo i.
- $\hat{y}_i^{(1:k)}$: lista de las primeras k predicciones.

- $1\{\cdot\}$: vale 1 si la condición es verdadera, 0 si no.

2. MRR (Mean Reciprocal Rank)

- Evalúa la posición del primer resultado relevante en una lista ordenada de resultados para cada consulta. Está en un rango de 0 a 1.
- **Fórmula:**

$$\text{MRR} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i}$$

Donde:

- $|Q|$ es el número total de consultas.
- rank_i es la posición del primer resultado relevante para la consulta i . Si no hay resultados relevantes, se considera $\frac{1}{\text{rank}_i} = 0$.

3. Mean Average Precision (mAP)

- Es la media de las precisiones promedio obtenidas para un conjunto de consultas. Está en un rango de 0 a 1.
- **Fórmula:**

$$\text{MAP} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \text{AP}_i$$

Donde:

- $|Q|$ es el número total de consultas.
- AP_i es la precisión promedio para la consulta i , calculada como:

$$AP_i = \frac{1}{m_i} \sum_{k=1}^n P(k) \cdot \text{rel}_i(k)$$

- m_i es el número total de documentos relevantes para la consulta i .
- n es el número total de documentos recuperados.
- $P(k)$ es la precisión en la posición k .
- $\text{rel}_i(k)$ es una función indicadora que vale 1 si el documento en la posición k es relevante para la consulta i , y 0 en caso contrario.

2.2 Explicación de los cuadernillos anexos

2.2.1 limpieza_fragmentos.ipynb

Este cuaderno de Jupyter automatiza el análisis de entrevistas mediante técnicas de procesamiento de lenguaje natural (NLP) y aprendizaje automático. Su objetivo es conectar datos codificados en Excel con fragmentos relevantes de las entrevistas transcritas, permitiendo un análisis semántico y temático más profundo.

Configuración Inicial:

- `PATH_EXCEL`: Ruta al archivo con las codificaciones manuales (Matriz codificación UCEVA.xlsx).
- `PATH_ENTREVISTAS_BASE`: Carpeta que contiene las entrevistas en formato .docx.
- `MODEL_NAME`: Modelo de SentenceTransformer usado para generar embeddings de texto (intfloat/e5-large).
- Umbrales y parámetros: similitud semántica (0.80), número de tópicos y palabras para LDA y TF-IDF (3, 10, 10).

Carga de Recursos: Se carga el modelo de lenguaje en español (`es_core_news_sm`) para establecer una lista de *stopwords* y mejorar la identificación de palabras clave.

Diccionario de Mapeo (`mapeo_preguntas`):

Estructura las preguntas y respuestas codificadas en lenguaje natural, generando frases descriptivas que se comparan con el texto de las entrevistas.

Funciones Clave:

- `cargar_entrevista`: Extrae turnos de habla de entrevistador y participante desde archivos

.docx.

- mejor_query: Crea descripciones semánticas a partir del diccionario de mapeo.
- PATRONES_RUIDO: Una lista de expresiones regulares definidas manualmente para identificar y eliminar palabras de relleno o muletillas comunes en el habla (ej. 'okey', 'emmm', 'este').
- normalizar_texto(texto): Realiza una normalización Unicode para estandarizar caracteres (ej. manejar tildes y caracteres especiales) y elimina caracteres de control.
- reducir_repeticiones(palabra): Reduce secuencias de letras repetidas en una palabra (ej. 'holaaa' -> 'hola'), con algunas excepciones.
- preprocesar_texto_sin_lematizar: Limpia el texto eliminando ruido (muletillas, repeticiones, símbolos) y estandariza su formato.

Procesamiento de Edad:

- limpiar_edad_inicio_fb: está diseñada para procesar la columna 'EDAD INICIO FB' del Excel, que puede tener la edad de inicio en Facebook en diversos formatos (ej. "11 años", "2012 (A los 11 años)", "2011"), extrae el valor numérico de la edad. Si se proporciona un año, calcula la edad basándose en AÑO_REFERENCIA_ENTREVISTAS.

Devuelve la edad como un número o NaN (Not a Number) si no se puede extraer. la limpieza y transformación de las columnas relacionadas con la edad en el DataFrame df_entrevistas. Categorización de Grupos de Edad ('GRUPO_EDAD'): Convierte la columna 'EDAD' a formato numérico. Los valores que no se puedan convertir se transformarán en NaN. Luego se Define rangos (bins_edad) y etiquetas (labels_edad) para crear grupos de edad (18-20, 21-23, 24-25 años). Se utiliza la función pd.cut para asignar cada sujeto a un grupo de edad, creando una nueva columna llamada 'GRUPO_EDAD' con los rangos establecidos

Los rangos establecidos para GRUPO_EDAD_INICIO_FB quedan como :

- Infancia (<10),
- Preadolescencia (11-13),
- Adolescencia (14-18),
- Mayor de 18

.Utiliza pd.cut para crear la columna 'GRUPO_EDAD_INICIO_FB' categorizando los valores de 'EDAD_INICIO_FB_NUM'. Los valores NaN en 'GRUPO_EDAD_INICIO_FB' se reemplazan por 'Edad inicio FB no especificada'.

•

Visualización del DataFrame Resultante:

- Se muestra el estado del DataFrame df_entrevistas, incluyendo las nuevas columnas derivadas del procesamiento de edad. En el ejemplo, contiene 86 filas y 19 columnas.

Análisis Principal:

- inicia un bucle que:
 - Itera sobre cada sujeto.
 - Carga y limpia su entrevista.
 - Genera descripciones desde el Excel codificado.
 - Compara semánticamente estas descripciones con el texto real mediante SentenceTransformer.
 - Aplica TF-IDF y LDA para identificar temas y palabras clave.
 - Se actualizan los query manualmente analizando los temas y palabras claves

Objetivos del cuaderno:

1. Preparar y estructurar datos desde Excel y entrevistas.
2. Conectar datos cuantitativos y cualitativos para validar codificaciones con evidencia textual.
3. Aplicar análisis semántico con modelos preentrenados.
4. Descubrir temas y patrones mediante TF-IDF y LDA.

En resumen, `limpieza_fragmentos.ipynb` facilita el análisis cualitativo automatizado de entrevistas al integrar técnicas de NLP y codificación manual, generando insights temáticos y semánticos validados por evidencia textual.

2.2.2 prediccion_fragmentos.ipynb

En este cuadernillo se describe el procedimiento para analizar una nueva entrevista. Está dividido en 2 secciones: en la primera se toma una perspectiva de cómo se pueden predecir nuevas entrevistas a partir de entrevistas previas (haciendo uso de los fragmentos extraídos previamente en `limpieza_fragmentos.ipynb`), y en la segunda se da un primer acercamiento a cómo analizar nuevas entrevistas sin tener una matriz de codificación previa.

Para el primer enfoque, se comienza cargando la matriz con la información sobre las entrevistas desde un archivo de Excel con las nuevas columnas del grupo de edad, creado en el primer cuadernillo. Luego, se filtra esta información para incluir solo las entrevistas que se van a utilizar como prueba. Asimismo, se define una estructura de datos llamada “*frases_generales*” que organiza los queries mediante los cuales se extraerán los fragmentos en los que es más posible

que se esté respondiendo esa pregunta en la entrevista.

Para este proceso se definieron previamente ciertas funciones:

- **cargar_entrevista():** Se mantienen las mismas funciones definidas previamente para la limpieza y extracción de pares Entrevistador/Participante para cada entrevista.
- **top_k_accuracy(), mean_reciprocal_rank(), mean_average_precision():** Calculan las métricas descritas previamente. También se crea una matriz de confusión para comparar las etiquetas reales contra las predichas y se muestran las métricas anteriores con la función **generar_matriz_confusion()**.
- **fragmentos_relacionados_nueva_entrevista():** Se le da una pregunta, y busca en la entrevista los fragmentos (partes de la conversación) que son más relevantes y que probablemente den respuesta a esa pregunta. Para hacer esto, convierte en embeddings tanto el query para la pregunta que hay en "*frases_generales*" como los fragmentos de pares sacados a partir de la función **cargar_entrevista()**, calcula qué tan similares son la pregunta y cada fragmento y elige los "k" fragmentos más similares (las "k" mejores respuestas). Para este caso, se usó un $k = 2$, es decir, los 2 fragmentos más importantes para responder a esa pregunta en particular.
- **top_fragmentos_similares():** Esta función coordina el proceso de clasificación de la nueva entrevista. Llama a **fragmentos_relacionados_nueva_entrevista()** para extraer los fragmentos relevantes, compara estos fragmentos con los de las entrevistas anteriores mediante la similitud del coseno (volviéndolos previamente en embeddings), y predice la categoría basándose en la categoría más frecuente entre los fragmentos más similares.

Teniendo esto en cuenta, para cada nueva entrevista que se va a analizar, el código sigue estos pasos:

1. **Leer la entrevista:** Se utiliza la función **cargar_entrevista()** para leer el archivo de Word de la entrevista y dividirla en pares de preguntas y respuestas.
2. **Extraer fragmentos relevantes:** Para cada pregunta de la entrevista, se utiliza la función **fragmentos_relacionados_nueva_entrevista()** para identificar los fragmentos de la nueva entrevista que son más relevantes para esa pregunta.
3. **Encontrar entrevistas similares:** Los fragmentos relevantes de la nueva entrevista se comparan con los fragmentos de las entrevistas anteriores que ya están categorizados. El código busca las entrevistas anteriores que contienen fragmentos que son muy similares semánticamente a los de la nueva entrevista.
4. **Predecir la categoría:** Basándose en las categorías de los fragmentos más similares de las entrevistas anteriores, el código predice la categoría a la que pertenece la nueva entrevista para esa pregunta. Por ejemplo, si la mayoría de los fragmentos similares de las entrevistas anteriores están etiquetados como "Urbano", el código predice que la nueva entrevista también pertenece a la categoría "Urbano" para la pregunta sobre Dónde Creció.
5. **Mostrar los resultados:** Los resultados del análisis se presentan de forma clara, mostrando para cada pregunta de la nueva entrevista:
 - Los fragmentos de la nueva entrevista que se consideraron más relevantes.
 - Las categorías predichas por el código.

- La similitud entre los fragmentos de la nueva entrevista y los de las entrevistas anteriores.
6. **Métricas de rendimiento:** Se muestra la matriz de confusión y métricas para cada variable en la matriz.

Para el segundo enfoque, se tiene la función **predecir_categoria()** la cual toma un fragmento de texto de una entrevista, la clave de una pregunta y el modelo de lenguaje. Su trabajo es comparar el fragmento con las descripciones de las posibles respuestas a esa pregunta y determinar cuál es la categoría de respuesta más similar. Devuelve la categoría predicha y su puntuación de similitud.

Para esta versión, se siguió el siguiente procedimiento:


1. **Definición del Esquema de Categorización:** Se utilizó el mismo diccionario de “*mapeo_preguntas*” utilizado en el cuadernillo previo.
2. **Identificación de los Sujetos de Estudio:** Con la matriz de codificación se extraen los identificadores de los entrevistados.
3. **Clasificación Automatizada de las Respuestas:** El sistema lleva a cabo un análisis individual de cada entrevista: para cada pregunta definida en la matriz de codificación, se determina igualmente cuál es el fragmento que mejor la responde, y después se revisa la similitud del coseno con los queries particulares para cada categoría. La que tenga mayor similitud es la que se tomará como la predicción
4. **Registro y Almacenamiento de los Resultados:** Los resultados del proceso de clasificación se organizan en una tabla, que proporciona una visión estructurada de las categorías asignadas a las respuestas. Esta tabla se almacena posteriormente en un archivo digital para su preservación y consulta.

3. Resultados

3.1 Análisis de resultados del primer enfoque de automatización

A continuación se describen los resultados variable por variable:


1. *Dónde creció:*



- Top-5 Accuracy: 0.969
- MRR (Mean Reciprocal Rank): 0.909
- MAP (Mean Average Precision): 0.879

Las métricas indican un alto rendimiento general en la recuperación de fragmentos relevantes para la variable "Dónde creció". Sin embargo, varias complicaciones podrían estar presentes. La distinción entre "rural" y "urbano" introduce una ambigüedad potencial, ya que los límites pueden ser difusos y subjetivos, como personas que hayan vivido una parte de su infancia en el casco urbano y otra en el campo, afectando la consistencia en la clasificación. Además, la variabilidad en las descripciones del lugar de crianza en las entrevistas dificulta la identificación precisa por parte del modelo. Otra complicación surge de un desbalance en la representación de las categorías "rural" y "urbano", lo que está sesgando el modelo hacia la clase mayoritaria, a pesar de las altas métricas generales.

2. Grupo de Edad




- Top-5 Accuracy: 0.895
- MRR (Mean Reciprocal Rank): 0.571
- MAP (Mean Average Precision): 0.549

El Top-5 Accuracy, con un valor de 0.895, indica que en la mayoría de los casos la edad correcta se encuentra dentro de las 5 principales predicciones del modelo. Esto sugiere una capacidad razonable para identificar un rango de edad aproximado. Sin embargo, las métricas MRR (0.571) y MAP (0.549) son notablemente más bajas, lo que señala una dificultad significativa para el modelo en clasificar la edad exacta o un rango muy preciso con similitudes del coseno altas. Esta discrepancia sugiere que, aunque el modelo a menudo incluye la edad correcta entre sus principales sugerencias, su capacidad para priorizar la edad más precisa es limitada.

Varias complicaciones pueden contribuir a este rendimiento. La edad puede expresarse de múltiples formas en el lenguaje natural, desde declaraciones directas (“tengo 22 años”) hasta referencias indirectas o aproximaciones (“estoy en mis veintes”, “nací en el 2000”). Esta variabilidad lingüística introduce un desafío para el modelo al intentar normalizar y comparar las respuestas. Además, el contexto en el que se menciona la edad también es crucial; fragmentos que contienen números en contextos no relacionados con la edad pueden confundir al sistema.


3. Grupo de Edad de Inicio en Facebook



- Top-5 Accuracy: 0.763
- MRR (Mean Reciprocal Rank): 0.532
- MAP (Mean Average Precision): 0.499

Estas métricas indican que el modelo tiene mayor dificultad para recuperar los fragmentos más relevantes que mejor representan la edad de inicio en Facebook. Las principales complicaciones se deben a la imprecisión de los recuerdos de los entrevistados sobre su edad de inicio, la subjetividad en las respuestas y la dificultad para interpretar referencias temporales vagas. Los rangos de edad amplios y solapados también contribuyen a la dificultad en la clasificación. Nuevamente ocurre el problema que los entrevistados no mencionan directamente la edad en la que empezaron en esta red social sino el año, cosa para la que el modelo no está preparada y genera que se malinterpreten los fragmentos extraídos.


4. Participación publicando



- Top-5 Accuracy: 0.889
- MRR (Mean Reciprocal Rank): 0.661
- MAP (Mean Average Precision): 0.605

Las métricas de ranking muestran un buen rendimiento general, pues aunque el modelo identifica las categorías relevantes, no siempre se priorizan los fragmentos más pertinentes para la categoría correcta. Esto implica que hay margen de mejora para refinar la precisión y recuperar los fragmentos más relevantes basados en la similitud del coseno. Las posibles complicaciones incluyen la subjetividad en la definición de las categorías, lo que dificulta la diferenciación entre niveles de participación similares. La variabilidad en la forma en que los entrevistados expresan su interacción en redes sociales y la dependencia del contexto también pueden generar inconsistencias.


5. Discurso



- Top-5 Accuracy: 0.643
- MRR (Mean Reciprocal Rank): 0.419
- MAP (Mean Average Precision): 0.406

Estas métricas fueron las más bajas de la investigación: Esto indica una dificultad significativa para el modelo en la clasificación del tipo de discurso en términos de identificar la categoría correcta. Las principales complicaciones surgen de la alta ambigüedad y subjetividad en la distinción entre los tipos de discurso, la variabilidad en la expresión y la interpretación, y la influencia del tema y el contexto: el discurso es una construcción compleja que involucra no solo el contenido de las palabras, sino también la intención, el tono y el contexto, y capturar estas sutilezas es un desafío para los modelos de lenguaje. Estos factores pueden hacer que fragmentos con similitud coseno alta pero con una relación tangencial con el tipo de discurso dominen la recuperación.

6. Ideología Política




- Top-5 Accuracy: 0.968
- MRR (Mean Reciprocal Rank): 0.703
- MAP (Mean Average Precision): 0.671

El modelo es altamente efectivo para clasificar la presencia o ausencia de ideología política, probablemente debido a la simplicidad de las categorías y la claridad de las expresiones ideológicas en muchos casos.

A pesar del buen rendimiento, existen desafíos en la definición precisa de "ausencia", ya que algunos entrevistados pueden tener opiniones políticas implícitas que no se expresan explícitamente. La influencia del contexto y el tema de las publicaciones también puede complicar la clasificación. Para mantener la alta precisión, es importante refinar continuamente la interpretación de la "ausencia" y considerar el contexto de las expresiones políticas.


7. Vida offline



- Top-5 Accuracy: 0.958
- MRR (Mean Reciprocal Rank): 0.659
- MAP (Mean Average Precision): 0.635

El Top-5 Accuracy de 0.958 indica que el modelo es muy bueno para recuperar fragmentos relevantes para la participación política offline. El MRR de 0.659 y el MAP de 0.635 sugieren que los fragmentos recuperados son generalmente pertinentes, aunque puede haber casos en los que fragmentos menos relevantes con alta similitud influyan en la predicción. La ambigüedad en la definición de "participación" y la variabilidad en la expresión pueden hacer que el modelo recupere fragmentos que capturan aspectos generales de la actividad en lugar de los detalles específicos de la participación política.


8. Acceso a Redes



- Top-5 Accuracy: 0.913
- MRR (Mean Reciprocal Rank): 0.594
- MAP (Mean Average Precision): 0.604

Como en el caso de algunas variables previamente, el modelo recupera fragmentos relevantes para la clasificación del acceso, aunque no siempre prioriza los fragmentos más precisos para distinguir entre las categorías. Las posibles complicaciones surgen de la ambigüedad en las definiciones de "condiciona" y "parcial," que implican grados sutiles de restricción. La variabilidad en cómo los entrevistados expresan estas limitaciones y el contexto de uso del acceso también pueden introducir imprecisiones. Mejorar la claridad de las categorías y considerar el contexto podría refinar la capacidad del modelo para recuperar los fragmentos más relevantes y precisos.


9. Tipo de familia 1



- Top-5 Accuracy: 0.912
- MRR (Mean Reciprocal Rank): 0.684
- MAP (Mean Average Precision): 0.664

Las categorías están bien definidas, lo que facilita la clasificación en teoría. Sin embargo, la forma en que los entrevistados describen sus hogares puede variar, además las relaciones familiares pueden ser complejas y no siempre se ajustan perfectamente a las categorías predefinidas. Las descripciones de las relaciones pueden ser extensas y detalladas, incluyendo matices que el modelo debe interpretar.


10. Tipo de familia 2 (Cohesión)



- Top-5 Accuracy: 0.759
- MRR (Mean Reciprocal Rank): 0.563
- MAP (Mean Average Precision): 0.554

El modelo está sesgado por la cantidad de fragmentos pertenecientes a la categoría de conectada. La cohesión familiar es un concepto subjetivo y complejo. Las descripciones de las relaciones emocionales pueden ser ambiguas y matizadas, lo que dificulta la clasificación precisa. La distinción entre "conectada" y "desligada," aunque definida, puede ser borrosa en la práctica, y los entrevistados pueden usar un lenguaje que implica elementos de ambas categorías, lo que confunde al modelo.


11. Exhaustividad



- Top-5 Accuracy: 0.875
- MRR (Mean Reciprocal Rank): 0.557
- MAP (Mean Average Precision): 0.553

El modelo tiene dificultades para clasificar el tiempo de uso correcto en los primeros lugares y que la precisión general de la clasificación es moderada. Esto implica que, si bien el modelo a menudo identifica un rango de uso de tiempo cercano al correcto, no siempre lo ordena con precisión. La cantidad de tiempo dedicado a una red social a menudo se estima y puede ser subjetiva ("paso mucho tiempo en Facebook", "lo uso un rato al día"). Sobre todo, los límites entre "ocasional", "frecuente" y "total" pueden ser difusos, y las personas pueden ubicarse en la frontera entre dos categorías.

12. Intención de Voto



- Top-5 Accuracy: 0.821
- MRR (Mean Reciprocal Rank): 0.730
- MAP (Mean Average Precision): 0.675

En general tiene buenos resultados. Existe un sesgo hacia Gustavo Petro, probablemente dado que los jóvenes suelen seguir sus ideales. Los entrevistados expresaban sus preferencias de voto de diversas maneras, desde declaraciones directas ("Voy a votar por X") hasta expresiones más ambiguas o condicionadas ("Estoy considerando votar por Y"). Asimismo, los fragmentos pueden incluir no solo la intención de voto, sino también las razones o argumentos que la respaldan. Sin embargo, las variaciones en la expresión de la intención de voto, la influencia de opiniones y argumentos, la indecisión y el contexto político pueden introducir desafíos

4. Discusión

4.1 Comparación interna: Diferencias entre LLMs

Como se mencionó previamente, se escogió el modelo intfloat/e5-large dada su mayor capacidad para capturar relaciones semánticas. Ahora bien, ¿por qué los modelos paraphrase-multilingual-MiniLM-L12-v2 y intfloat/multilingual-e5-base no resultaron útiles para el proyecto actual? Hay varios motivos

Para comprender por qué el modelo intfloat/e5-large supera a los otros en la tarea de analizar

entrevistas a universitarios colombianos, es crucial analizar sus diferencias arquitectónicas y de capacidad. E5-large se distingue por su profundidad, con 24 capas de Transformer en comparación con las 12 de los otros modelos. Esta mayor profundidad le permite construir una representación jerárquica y más abstracta del lenguaje, capturando no solo las relaciones sintácticas sino también las sutilezas semánticas complejas que caracterizan el habla. Además, con aproximadamente 335 millones de parámetros, e5-large tiene una capacidad de almacenamiento de información significativamente mayor, lo que le permite internalizar patrones lingüísticos específicos del contexto, como el vocabulario universitario, las expresiones idiomáticas colombianas y las referencias culturales.

La dimensión de los embeddings también juega un papel fundamental. E5-large genera embeddings de 1024 dimensiones, en contraste con los 384 y 768 de los modelos más pequeños. Esta mayor dimensionalidad permite una representación más rica y detallada del significado, donde cada dimensión puede codificar diferentes aspectos semánticos como el tema, el tono emocional o el nivel de formalidad. Esto es particularmente importante para discernir entre respuestas que comparten similitudes superficiales pero difieren en matices sutiles de opinión o actitud. La capacidad de e5-large para capturar estas sutilezas es esencial para el análisis preciso de las entrevistas, donde el lenguaje coloquial, los regionalismos y las referencias culturales son frecuentes.

Más allá de su arquitectura, el entrenamiento específico de los modelos "e5" para tareas de recuperación de información les confiere una ventaja adicional. El esquema text2vec al que fueron sometidos los entrena para generar embeddings que maximizan la similitud entre consultas y documentos relevantes, mientras minimizan la similitud con los irrelevantes. E5-large refina aún más este proceso mediante el uso de una sintaxis especial que distingue entre la "consulta" (la pregunta) y el "documento" (el fragmento de la entrevista), lo que le permite enfocar su atención en la información más pertinente.

En el contexto específico de las entrevistas a universitarios colombianos, e5-large demuestra su superioridad al entender las particularidades del "español colombiano" con su jerga, regionalismos y referencias culturales. Su capacidad para discernir entre matices de opinión y actitud, así como para capturar el contexto académico y social relevante para esta población, lo convierte en la herramienta ideal para esta tarea. Los modelos más pequeños, al carecer de esta capacidad de representación rica y contextualizada, se quedan cortos en la precisión de la identificación de fragmentos relevantes, lo que subraya la importancia de elegir un modelo de lenguaje adecuado para la complejidad del dominio específico.

4.2 Comparación externa: Diferencias con otras investigaciones

Para contextualizar nuestro proyecto de automatización de codificación temática de entrevistas mediante Modelos de Lenguaje de Gran Escala (LLMs), es útil compararlo con otras investigaciones recientes que también exploran el uso de LLMs en diferentes contextos de análisis de texto. Analizaremos dos estudios: uno centrado en el análisis de cambios en archivos web y otro que evalúa la aplicabilidad de métodos de investigación cualitativa a las interacciones

con LLMs.

El primer estudio, titulado "Exploring Large Language Models for Analyzing Changes in Web Archive Content: A Retrieval-Augmented Generation Approach", aborda el desafío de analizar cambios a lo largo del tiempo en el contenido de páginas web archivadas. Tradicionalmente, este análisis ha sido un proceso manual que se basa en diferencias a nivel de términos o frases. Esta investigación propone el uso de LLMs, específicamente GPT-4o, a través de un enfoque de Retrieval-Augmented Generation (RAG).

El enfoque RAG, como se describe en este estudio, es un pipeline que combina la capacidad de los LLMs para generar texto con la habilidad de recuperar información relevante de una base de conocimiento externa. En este caso, la base de conocimiento son colecciones de archivos web en formato WARC. La herramienta utilizada es WARC-GPT, una herramienta de código abierto que implementa este pipeline RAG. Cuando un usuario realiza una consulta, WARC-GPT codifica la consulta, recupera fragmentos relevantes de los archivos WARC almacenados en una base de datos vectorial, y utiliza estos fragmentos recuperados junto con la consulta para que el LLM (como GPT-4o) genere una respuesta informada. El objetivo principal de este estudio es explorar si los LLMs pueden detectar inconsistencias y analizar cambios en el contenido archivado, considerando el contexto semántico, superando las limitaciones de los métodos tradicionales que solo detectan adiciones o eliminaciones de términos. La investigación encontró que GPT-4o sí podía detectar cambios y proporcionar análisis contextualizados, representando un paso inicial hacia el uso de la IA para un análisis de cambios web más profundo y escalable.

El segundo estudio relevante es "Qualitative Research Methods for Large Language Models: Conducting Semi-Structured Interviews with ChatGPT and BARD on Computer Science Education", que explora una aplicación muy diferente de los LLMs. Este estudio evalúa la aplicabilidad de los métodos de investigación cualitativa, específicamente el análisis de contenido cualitativo, a las respuestas obtenidas al realizar entrevistas semi-estructuradas con LLMs como ChatGPT (en inglés y alemán) y BARD. La premisa es que, dada la gran cantidad de datos y perspectivas sobre las que se entrenan estos modelos, "entrevistarlos" podría dar insights sobre opiniones públicas. El tema ejemplar elegido para las entrevistas fue la relevancia y la implementación de la educación en ciencias de la computación en la educación.

Los autores realizaron entrevistas con los LLMs y luego aplicaron métodos tradicionales de análisis de contenido cualitativo a las transcripciones generadas. Sus hallazgos indican que, si bien es posible aplicar métodos de análisis de contenido cualitativo a las respuestas de los LLMs, los resultados variaron fuertemente entre los diferentes modelos, entre los idiomas utilizados y incluso dentro del mismo modelo en entrevistas repetidas. Encontraron que las respuestas de los LLMs podían ser ambiguas, imprecisas o genéricas, y a veces citaban fuentes inexistentes. A pesar de la posibilidad técnica de aplicar métodos cualitativos, los autores generalmente no recomiendan usar LLMs para la recolección de datos cualitativos con fines académicos debido a sus resultados impredecibles e inestables. Sugieren su uso más bien como herramientas de exploración inicial para obtener diferentes perspectivas, o para probar pautas de entrevista antes de aplicarlas a participantes humanos.

Comparando este proyecto con estos dos estudios:

1. Tarea y Objetivo Principal:

- Este informe se enfoca en automatizar la codificación temática de *entrevistas humanas previamente transcritas*, con el objetivo de sugerir etiquetas para variables de análisis y reducir el esfuerzo manual.
- El estudio de "Exploring" se centra en el análisis de *cambios en contenido web archivado* utilizando RAG para proporcionar contexto semántico a esos cambios.
- El estudio de "Qualitative" evalúa la viabilidad y confiabilidad de los LLMs como "participantes" en *investigación cualitativa*, aplicando análisis de contenido humano a las respuestas generadas por los modelos.

2. Metodología y Enfoque de LLM:

- Nuestro proyecto utiliza LLMs principalmente para generar embeddings (representaciones numéricas de texto) y calcular similitud semántica (similitud del coseno) entre fragmentos de entrevista y consultas/categorías predefinidas para la clasificación automatizada. Aunque mencionamos el enfoque RAG (implícitamente al usar modelos como intfloat/e5-large entrenados para recuperación), nuestro uso es más directo para la comparación y clasificación basada en embeddings.
- El estudio de "Exploring" emplea explícitamente el pipeline RAG, donde un LLM genera texto *basándose* en fragmentos de texto *recuperados* de una base de conocimiento externa.
- El estudio de "Qualitative" utiliza LLMs como generadores de texto en respuesta a prompts (las preguntas de la entrevista) y luego somete ese texto a un análisis cualitativo humano tradicional, sin un proceso de recuperación de datos externo integrado en el LLM durante la "entrevista".

3. Tipo de Datos de Entrada/Análisis:

- Nuestro proyecto analiza transcripciones de entrevistas humanas reales.
- El estudio de "Exploring" analiza contenido de páginas web archivadas (archivos WARC).
- El estudio de "Qualitative" analiza texto generado directamente por los LLMs en respuesta a preguntas.

4. Evaluación del LLM:

- En nuestro proyecto, evaluamos el rendimiento de diferentes modelos de embedding para la tarea de clasificación, utilizando métricas cuantitativas estándar como Top-k accuracy, MRR y mAP. También validamos la elección del modelo basándonos en su capacidad para capturar los matices semánticos del español colombiano y el contexto específico de las entrevistas.
- El estudio de "Exploring" evaluó la capacidad del LLM para detectar y contextualizar cambios, validando las respuestas generadas contra el contenido original a través de evaluación humana.

- El estudio de "Qualitative" evaluó la aplicabilidad de los métodos cualitativos humanos a las respuestas del LLM y la variabilidad/confiabilidad de los LLMs como fuentes de información cualitativa.

En resumen, aunque los tres estudios aprovechan el poder de los LLMs, lo hacen para tareas, datos y metodologías fundamentalmente diferentes. Mientras que "Exploring" utiliza LLMs en un pipeline RAG para analizar datos externos (archivos web), y "Qualitative" evalúa a los LLMs como "sujetos" de investigación cualitativa, nuestro proyecto aplica los LLMs para automatizar el análisis (codificación) de datos externos (entrevistas humanas) mediante la similitud semántica. Esto destaca la versatilidad de los LLMs y los diferentes enfoques que se están explorando para integrar estas tecnologías en diversas áreas de análisis de texto.

5. Conclusiones

La automatización de la codificación temática en entrevistas es una respuesta viable y necesaria al problema de la demora y el error humano inherente a la codificación manual. Esta tarea manual de analizar individualmente cada entrevista con múltiples variables es muy laboriosa.

El proyecto exploró exitosamente el uso de técnicas de Procesamiento de Lenguaje Natural (PLN), específicamente Modelos de Lenguaje de Gran Escala (LLMs) basados en la arquitectura Transformer, para automatizar la codificación de entrevistas. El objetivo principal fue automatizar la codificación de nuevas entrevistas en la matriz existente, sugiriendo automáticamente posibles etiquetas para las variables de análisis y reduciendo la carga del análisis cualitativo manual.

- Los LLMs son particularmente útiles para esta tarea porque están diseñados para la comprensión y generación de texto, entendiendo los patrones del lenguaje mediante representaciones numéricas como los embeddings.
- La metodología desarrollada permite analizar nuevas entrevistas prediciendo categorías basándose en la similitud semántica con entrevistas previamente codificadas. Esto implica extraer fragmentos relevantes de la nueva entrevista, convertirlos en embeddings, compararlos mediante la similitud del coseno con fragmentos de entrevistas anteriores, y predecir la categoría que es más frecuente entre los fragmentos más similares.
- Un reto significativo identificado fue la creación y mejora de los queries (consultas) utilizados para extraer fragmentos relevantes. Comprender la gran variedad de discursos que responden a una misma pregunta supuso una dificultad.

Referencias

Powell, A.(2025). *Should universities be taking official stances on political, social issues of day?*

Harvard Gazette.

<https://news.harvard.edu/gazette/story/2024/03/should-universities-be-taking-official-stances-on-political-social-issues-of-day/>

Liliana, G. R., Juliana, C. M., & Fabián, A. S. (2010). *Política y juventud en la vida universitaria: Un estudio de caso.*

https://ve.scielo.org/scielo.php?pid=S1315-52162010000300006&script=sci_arttext&utm

Ahmed, N. (2022). *Natural language processing techniques for political opinion & sentiment.*

<https://dash.harvard.edu/entities/publication/ee1b66c8-cf96-40d9-af1a-b28bba792a35>

J. G. Botello, L. Frew, J. J. Padilla and M. C. Weigle, "Exploring Large Language Models for Analyzing Changes in Web Archive Content: A Retrieval-Augmented Generation Approach," in 2024 IEEE International Conference on Big Data (BigData)

<https://www.computer.org/csdl/proceedings-article/bigdata/2024/10826069/23yldNrzhC>

Dengel, Andreas & Gehrlein, Rupert & Fernes, David & Görlich, Sebastian & Maurer, Jonas & Pham, Hai & Großmann, Gabriel & Eisermann, Niklas. (2023). Qualitative Research Methods for Large Language Models: Conducting Semi-Structured Interviews with ChatGPT and BARD on Computer Science Education. Informatics. 10. 78. 10.3390/informatics10040078.

https://www.researchgate.net/publication/374685291_Qualitative_Research_Methods_for_Large_Language_Models_Conducting_Semi-Structured_Interviews_with_ChatGPT_and_BAR_D_on_Computer_Science_Education

Bisgin, H., & Mani, M. (2022). *Using Natural Language Processing to Analyze Political Party Manifestos from New Zealand*. <https://deepblue.lib.umich.edu/handle/2027.42/175827>

Bell, E. (2022). *Inteligencia artificial Generativa frente a grandes modelos de lenguaje (LLM): ¿Cuál es la diferencia?*
<https://appian.com/es/blog/acp/process-automation/generative-ai-vs-large-language-models>

Ibm. (2025). What is self-attention? *IBM*.
<https://www.ibm.com/think/topics/self-attention#:~:text=Self%2Dattention%20is%20a%20type,understand%20the%20relations%20between%20them>.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). *Attention is all you need*. arXiv.org.
<https://arxiv.org/abs/1706.03762>

Hugging Face - documentation. (s.f). <https://huggingface.co/docs>

Wang, W., Wei, F., Dong, L., Bao, H., Yang, N., & Zhou, M. (2020). *MINILM: Deep Self-Attention Distillation for Task-Agnostic Compression of Pre-Trained Transformers*. arXiv.org. <https://arxiv.org/abs/2002.10957>